Universidade do Minho

Mestrado Integrado em Engenharia Informática

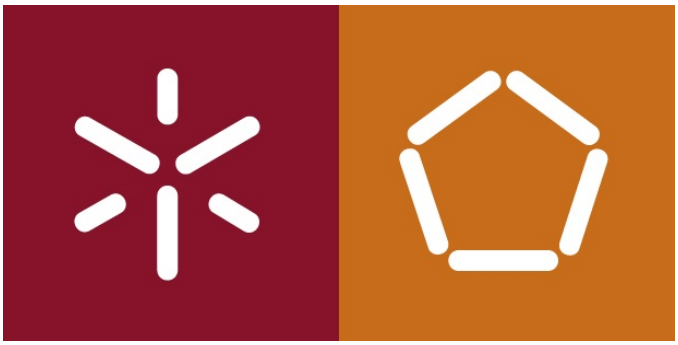

Stack Overflow

Laboratórios de Informática III

Grupo 51

Carla Cruz
A80564

Maria Dias
A81611

Pedro Freitas
A80975

May 5, 2018

Contents

Introdução

No âmbito da unidade curricular de Laboratórios de Informática III do segundo ano do Mestrado Integrado em Engenharia Informática foi proposto o desenvolvimento de um projeto em linguagem C que visa o desenvolvimento de um sistema capaz de processar ficheiros XML que armazenam as várias informações utilizadas pelo Stack Overflow e a execução de um conjunto de interrogações de forma eficiente, tendo por objetivo a consolidação e enriquecimento dos conhecimentos adquiridos nas Unidades Curriculares de Programação Imperativa e de Algoritmos e Complexidade.

Este projeto considera-se um grande desafio pelo facto de passarmos a realizar programação em grande escala, uma vez que processamos ficheiros com grandes volumes de dados e lidamos com uma maior complexidade algorítmica e estrutural. Nesse sentido, o desenvolvimento deste programa será realizado a partir dos princípios da modularidade (divisão do código fonte em unidades separadas coerentes), do encapsulamento (garantia de proteção e acessos controlados aos dados), da conceção de código reutilizável e de uma escolha otimizada das estruturas de dados.

Leitura dos dados e Extração de Informação

Existem dois backups de diferentes comunidades e volume de posts (i.e., android e ubuntu). Cada backup é composto por oito ficheiros XML - Votes, Tags, Users, PostLinks, Posts, PostHistory, Comments e Badges). Para a realização do projeto consideramos relevantes para leitura e extração de dados apenas os ficheiros Users, Posts e Tags, pelo que só serão guardadas as informações contidas nestes ficheiros.

Descrição dos Módulos

A arquitetura do software é definida pelos módulos principais Users (utilizadores), Posts (publicações - que podem ser perguntas, respostas, comentários...) e Tags, cujas fontes de dados são os ficheiros .xml *Users.xml*, *Posts.xml* e *Tags.xml*.

parser.h

Os ficheiros previamente fornecidos encontravam-se no formato XML, havendo assim a necessidade de os converter para serem inseridos nas estruturas por nós escolhidas e para que pudesse ser efetuado o armazenamento dos dados em questão. Para realizar o parsing destes ficheiros, foi usada a biblioteca *Libxml2* e criado um módulo independente que serve o propósito de processar todos os ficheiros .xml. Para guardas as informações contidas nestes ficheiros, optamos por utilizar a biblioteca *glib*.

Aquando do parsing do ficheiro *Users.xml*, a informação relativa aos users é guardada numa AVL ordenada pelo id de cada um.

No caso do ficheiro *Posts.xml*, os dados são primeiramente guardados numa AVL ordenada pelo id de cada post e adicionalmente inseridos em arrays dinâmicos, que guardam todas as publicações que foram efetuadas numa determinada data. Estes arrays, por sua vez, são inseridos numa tabela de Hash, tendo cada posição da tabela um array com todas as publicações criadas num certo dia.

myuser.h

Este ficheiro contém a API relativa à implementação de um User. Cada User alberga o ID (long), a reputação (int), o nome (char*), o perfil (char*), o número de posts (int) e a árvore (Heap) - definida em heap.h - de posts de cada utilizador.

mypost.h

Este ficheiro contém a API relativa à implementação de um Post. Cada Post alberga o ID (long) da publicação, o seu tipo (int), o ID (long) da pergunta à qual responde, se se tratar de uma pergunta, o score (int), o número de visualizações (int), a data (Date) de criação, o ID (long) do criador, a reputação (int) do criador, o número de comentários (int), o número de respostas (int), o título (char*), o array de tags (char**) e o número de tags (int). Neste ficheiro também é implementado um array dinâmico, que contém os Posts de um determinado dia, sendo estes armazenados, numa

tabela de Hash, em que o seu indice é o valor de acha calculado com base na data do mesmo. Estes Posts são inseridos à medida que se dá a leitura do ficheiro dos Posts.

mytags.h

Este ficheiro contém a API relativa à implementação de uma **Tag**. Cada **Tag** alberga o ID(long) da tag e o seu respetivo Nome(char*).

heap.h

Como forma de responder às interrogações de forma mais eficiente, foi criada uma Max Heap capaz de ordenar os posts de quatro formas diferentes - data mais recente, score, número de respostas e classificação média do post (segundo a expressão apresentada na query 10).

Para além de ser usada em várias interrogações, esta estrutura está também implementada na estrutura criada para os Users no ficheiro myuser.h, e guarda todos os posts de um dado user por ordem cronológica inversa.

heapU.h

Tal como a estrutura anterior, esta foi criada de forma a facilitar a resposta eficiente às interrogações propostas. Trata-se de uma Max Heap que ordena IDs por uma dada quantidade que lhe é passada, sendo, por isso, uma estrutura mais geral do que a anterior (que só pode ser aplicada a posts).

arrayT.h

Tal como as anteriores, esta estrutura foi criada para facilitar a resposta ao problema. Trata-se de um array dinâmico de pares Tag-Num. Este par (**TNum**) é composto pelo nome da Tag (char*) e o número de ocorrências da mesma num determinado número de Posts(int). O array dinâmico é preenchido ao longo que lhe são passados Posts.

key.h

Esta estrutura implementa um apontador para long. Foi criada com o intuito de facilitar a utilização das estruturas definidas na biblioteca *glib*.

util.h

Este ficheiro contém algumas estruturas - *ResPost* e *Duplos* - e funções auxiliares que permitem responder fácil e eficientemente às interrogações.

Interrogações

Após o desenho e a implementação das estruturas que servem de suporte ao desenvolvimento do programa pretendido, surge agora o momento de tirar partido de tais estruturas e começar a fazer interrogações ao programa, com o intuito de demonstrar o seu nível de praticalidade para o problema em questão e também perceber o nível de fiabilidade que ele proporciona.

Antes de interrogar o programa, é feita uma inicialização da estrutura *TAD_ community*, o que equivale a dizer que se inicializam as árvores dos Posts, Users e Tags, e a Hash Table dos Posts. Posteriormente, é efetuado o carregamento de dados para as estruturas, o que acontece, como já foi referido, no parser.

Depois da inicialização e do load da *TAD_ community*, o programa está apto a responder às interrogações especificadas. Para isso, recorremos às estruturas criadas para nelas procurarmos a informação pretendida, através de funções definidas. Finalmente, seguido da resposta às interrogações, é necessário libertar o espaço em memória alocado pelas estruturas utilizadas. Para esse efeito, é definida uma função *clean* que limpa toda a informação da estrutura.

No ficheiro interface.c estão codificadas todas as interrogações definidas, as quais serão abordadas de seguida.

Interrogação 1

Esta interrogação retorna o título e o nome do autor de um post, dado o id do mesmo. Caso o post dado seja uma resposta, deverá retornar as informações (título e autor) da pergunta correspondente.

Estratégia: Para responder a este problema procuramos o Post na árvore dos Posts com esse id. De seguida verifica-se qual o tipo do Post. Se este for do tipo 1 (pergunta) através do OwnerUserId procuramos o User que é dono desse post e devolvemos um par com o título da pergunta e o username do dono. Se for do tipo 2 (resposta), através do ParentId encontramos a pergunta à qual esta resposta pertence e fazemos o mesmo procedimento do tipo 1.

Interrogação 2

Esta interrogação pretende obter o top N utilizadores com maior número de posts de sempre, tendo em conta todas as perguntas e respostas dadas por cada utilizador.

Estratégia: Para responder a esta interrogação, acedemos à árvore de Posts de cada utilizador, contando o número de nodos que cada árvore contém. Com base neste valor, é criada uma Heap que é ordenada com base nos valores lidos. No final é feito , N vezes, o pop desta Heap gerada e inserimos numa lista ligada os id's correspondentes a cada nodo retirado.

Interrogação 3

Esta interrogação procura, dado um determinado intervalo de tempo, obter o número total de posts (identificando perguntas e respostas separadamente) efetuados nesse período.

Estratégia: Dado a data de início e fim deste intervalo de tempo, foi possível consultar este intervalo de tempo na tabela de Hash,(usando a função incrementaData para avançar sucessivamente), em que cada dia continha o respetivo número de perguntas e respostas dadas. Estes valores

foram somados, obtendo assim, o valor todas de perguntas e respostas dadas no intervalo de tempo dado.

Interrogação 4

Esta interrogação retorna os ids de todas as perguntas contendo uma dada tag, por ordem cronológica inversa da data das perguntas.

Estratégia: Para responder a esta interrogação, acedemos a todas as posições da tabela de Hash de Posts que correspondem ao período de tempo dado, e em cada um dos arrays de Posts foram filtradas as publicações do tipo pergunta, cujo título continha a tag dada (percorrendo todas as tags da pergunta e comparando com a tag fornecida), e foram depois inseridas numa heap ordenada pela data mais recente.

Finalmente, removemos da Heap e inserimos numa lista ligada todos os Posts, resultando numa lista ordenada por ordem cronológica inversa, como era pedido.

Interrogação 5

Esta interrogação retorna a informação do perfil e as últimas dez publicações de um user do qual é dado o ID.

Estratégia: Dado o ID do user, procuramos na árvore dos users aquele que tinha esse mesmo ID e recorremos a duas funções auxiliares que, dado um User, retornam o seu perfil e a Heap dos seus Posts, ordenados por ordem cronológica inversa. Desta Heap, fazemos pop de dez publicações, ficando com os dez Posts mais recentes deste User.

Finalmente, criamos um USER com o perfil e posts que calculamos, e retornamos essa informação.

Interrogação 6

Esta interrogação procura, dado um determinado intervalo de tempo, obter os ids das N respostas com mais votos, por ordem descrescente do número de votos.

Estratégia: Acedemos à tabela de Hash de Posts e filtramos os arrays que contêm as publicações criadas no período de tempo em questão, sendo depois cada um desses arrays percorrido, filtrando as publicações do tipo resposta. Posteriormente, esses Posts foram inseridos numa Heap inicialmente vazia, ordenada pelo Score dos mesmos. Para obter a lista ligada das N respostas com mais votos (sendo que os votos são equivalentes ao Score da resposta), fizemos pop de N Posts da Heap, e inserimos os IDs correspondentes na lista a devolver, ficando assim com uma lista ordenada por ordem decrescente do número de votos das respostas.

Interrogação 7

Esta interrogação retorna os IDs das N perguntas com mais respostas num dado intervalo de tempo, por ordem decrescente do número de respostas.

Estratégia: Tal como foi feito para as restantes interrogações que envolvem um dado intervalo de tempo, acedemos à tabela de Hash de Posts e filtramos os arrays que contêm as publicações criadas nesse período. De seguida, cada um desses arrays foi percorrido, calculando o número de respostas de cada publicação e inserindo todos os Posts numa Heap inicialmente vazia, ordenada pelo maior número de respostas (efetuadas também no intervalo de tempo em questão). Para obter a lista ligada das N perguntas com mais respostas, fizemos pop de N Posts da Heap, e inserimos os IDs correspondentes na lista a devolver, ficando assim com uma lista ordenada por ordem decrescente do número de respostas.

Interrogação 8

Esta interrogação devolve os IDs das N perguntas cujos títulos contêm uma dada palavra, por ordem cronológica inversa destas.

Estratégia: Para responder a esta interrogação, inicializamos uma Max Heap e preenchemo-la com todos os posts que contêm uma dada palavra, à medida que percorremos a árvore de Posts. A heap é ordenada conforme a data mais recente. Para obter a lista ligada que se pertende retornar, fazemos pop de N Posts da heap e inserimos o seu ID na lista ligada, ficando assim com uma lista ordenada por ordem cronológica inversa.

Interrogação 9

Esta interrogação devolve as últimas N perguntas (por ordem cronológica inversa) em que participaram dois utilizadores específicos.

Estratégia: Nesta questão, para cada utilizador, percorremos a árvore de Posts respetiva a cada um. Caso o tipo dos Posts do ID 1 fosse 1, e encontrassemos um do tipo 2 correspondente ao ID 2, verificavamos se o Post comentado pelo ID 2 era correspondente ao publicado do ID 1 e vice-versa. Caso ambos fossem do tipo resposta, verificavamos se o Post comentado por ambos coincidia. Se estas verificações fossem verdadeiras, inserimos o Post numa Heap ordenada por ordem cronológica inversa. No final fizemos o pop da Heap, inserindo os ID's lidos, numa lista, sendo esta retornada.

Interrogação 10

Esta interrogação devolve a melhor resposta dada a uma certa pergunta, da qual é passada o ID.

Estratégia: Percorremos a árvore de Posts, e todas as publicações que são resposta à pergunta dada são inseridas numa Max Heap inicialmente vazia, e são ordenadas conforme a fórmula dada para calcular a sua classificação média. No final, é retirado o maior elemento da heap (que é do tipo Post), e é calculado e devolvido o seu ID.

Interrogação 11

Esta interrogação retorna, dado um intervalo de tempo, os IDs das N tags mais utilizadas pelos N utilizadores com melhor reputação, naquele período.

Estratégia: Dado um determinado número inteiro N criamos uma lista com esse tamanho e são feitos N pops na estrutura heapU que,ordenados pela reputação, nos preenche essa lista com os N users com mais reputação. Já obtida a lista o passo seguinte é percorrer a heap com todos os posts de cada user presentes nessa mesma lista. Nessa execução é utilizada uma estrutura auxiliar ATNum (array dinâmico de TNum - Pares de Tag-Número de ocorrência). Para cada post percorrido verifica-se se esse post pertence ao intervalo dado e ,caso pertença, percorre-se todas as tags do mesmo, guardando na estrutura ATNum. Se a tag já estiver guardada nessa estrutura é incrementado o número de ocorrências dessa tag. Obtendo todas as tags e o número de ocorrências das mesmas, ordenamos o nosso ATNum de forma decrescente segundo o número de ocorrências de cada tag. Por fim para obter o id das N tags mais usadas, ao mesmo tempo que percorremos a estrutura ATNum, fazemos uma procura na estrutura TCD community em que procuramos a correspondência de cada tag da ATNum, obtendo assim o seu id. Para esta procura foi necessário uma função gboolean, onde o último parâmetro seria uma estrutura Duplos com a LONG list a ser preenchida e com um TNum com a tag a ser comparada. Cada id é guardado e depois retornado na LONG list.

Resultados e Testes de Performance

Após o desenvolvimento e codificação do projeto, foram realizados alguns testes de performance, que consistem na obtenção dos tempos de execução das interrogações, usando os backups *android* e *ubuntu*, dos quais lemos os ficheiros Users.xml, Posts.xml e Tags.xml, usando a biblioteca standard de C *time.h*.

Uma vez que a quantidade de dados aumenta do backup android para o backup ubuntu, é aceitável que os tempos de execução para os carregar, ou seja, a fase de leitura e inserção de dados, também aumente consideravelmente. Comparando os valores de tempo de execução das interrogações, é possível observar nos gráficos que o tempo de execução não varia significativamente, uma vez que são registadas variações na ordem dos milissegundos, devido a uma estruturação dos dados independente da quantidade de dados acumulada.

Estes testes foram realizados numa máquina com um processador de 3,1GHz, com uma memória Ram de 8GB.

Grafo de Dependências

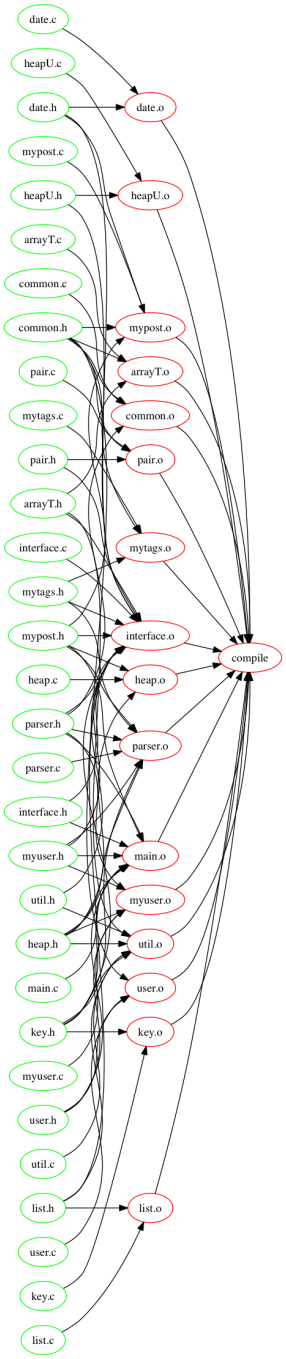

Figure 1: Grafo de dependências

Conclusão

Ao longo deste projeto trabalhamos com blocos de dados de tamanho muito maior ao que tínhamos feito até então, forçando à utilização de técnicas particulares, como as que foram mencionadas na introdução deste relatório. A estratégia seguida foi a de conceber o trabalho de forma a que fosse facilmente modificável e, apesar da complexidade, o mais otimizado possível.

As maiores dificuldades existiram na implementação da abstração de dados, com o objetivo de delimitar a vista do utilizador, pois era uma prática não conhecida até este ponto e exige um cuidado acrescido por parte do programador ; na limpeza das estruturas, devido ao facto de não haver conhecimento entre os módulos; na gestão das estruturas de forma eficiente, para obter uma boa performance.

Consideramos que este trabalho foi muito importante para o aprofundar do conhecimento no que toca ao uso da linguagem C e apreendimento das técnicas abordadas ao longo do relatório, sem esquecer o uso de algumas das ferramentas que nos foram apresentadas no desenvolver do projeto (como o valgrind), que nos ajudaram a progredir como programadores e a ter uma maior autonomia na correção de erros.